

Political Digital Twin de Colombia

Modelo de datos, catálogo con auditoría de población completa, identidad de partido y persona resueltas, trayectorias políticas, y seis módulos analíticos (outsiders, ADN político, red de poder, forecasting, simulación, dashboard) sobre los 9 cargos de elección popular, 1958–2023.

128

archivos electorales, 9 cargos, auditados en población completa (no muestra)

11,2M

filas cargadas: cámara, senado, presidencia, asamblea, concejo, gobernación, alcaldía

101.209

personas (identidad resuelta) con al menos una elección ganada

783.376

candidaturas en el vector de features, base de los 6 módulos analíticos

I. El modelo de datos

Un Master Data Model construido dos veces: la primera versión dependía de la clasificación de partidos de CEDE; se descartó porque no comparte una llave limpia con los resultados electorales.

El modelo canónico (`political-digital-twin-colombia/docs/MDM.md`) define ocho entidades de Fase 1 — `partido`, `partido_participacion_nivel`, `tipo_eleccion_cargo`, `departamento`, `municipio`, `municipio_codigo_historico`, `eleccion`, `resultado_electoral` — construidas **únicamente** a partir de los archivos de resultados electorales, no de la clasificación de partidos de CEDE (`partidos.xlsx`).


La razón del cambio: `partidos.xlsx` identifica cada partido con un código numérico propio, pero los archivos de resultados usan el mismo nombre de columna (`codigo_partido`) para guardar el **nombre** del partido en texto libre — no hay llave compartida entre ambas fuentes sin recurrir a coincidencia de texto aproximada. En vez de heredar esa fragilidad, `partido` ahora se **deriva** directamente de los nombres que aparecen en los resultados: la llave siempre resuelve, por construcción, a costa de perder la clasificación ideológica y la membresía de coalición que solo existían en la fuente descartada.

II. El catálogo de datos

Ocho datasets, con auditoría de calidad ya recalculada sobre **población completa** — los 128 archivos, no una muestra dirigida.

Registros por dataset (escala logarítmica)


Población completa — conteo exacto de los 128 archivos.



"Codigo_partido" vacío, por cargo (población completa)

No es dato faltante: son categorías administrativas por municipio (votos nulos, votos en blanco, tarjetas no marcadas, y en corporaciones locales también candidaturas retiradas o revocadas). Su peso relativo sube cuando compiten pocos candidatos reales (segunda vuelta presidencial) y baja cuando compiten muchos (cámara, concejo).





Tres esquemas de columnas, no uno

Los 128 archivos no comparten estructura: una variante **antigua** (1958--~1994, con coddpto_anti/codmpio_anti), una **intermedia** (~1997--~2007, sin sufijo de vigencia) y una **reciente** (2010--2023, con coddpto_reg/codmpio_reg y censo electoral). Gobernación usa además una variante propia (coddpto91) solo en su primer archivo, de 1991.

III. Calidad de los datos


La auditoría de **población completa** (128 archivos, no muestra) reveló un pico de corrupción que la muestra dirigida de 8 años se saltó por completo: 1991.


HALLAZGO CRÍTICO — NO DETECTADO POR LA MUESTRA DIRIGIDA

1991 tiene 31,4% de filas con nombre de partido corrupto en cámara y 14,7% en senado — un orden de magnitud por encima de cualquier otro año/cargo del proyecto (el máximo anterior conocido era 3,05%, cámara 2022). La muestra original de 8 años (1958, 1962, 1974, 1990, 2002, 2010, 2018, 2022) simplemente no incluía 1991 — una muestra dirigida por década puede saltarse por completo el peor caso si cae fuera de los puntos elegidos. Solo se vio al auditar los 128 archivos completos.

Filas con nombre de partido corrupto, por año (todos los cargos, población completa)

Caracteres acentuados reemplazados por ? literal en la fuente, irrecuperable de forma determinística. La corrupción es específica de archivo/año, no una tendencia de "lo viejo es peor" — pero tampoco es uniformemente baja: 1991 y 2006 muestran que puede dispararse sin patrón aparente.





HALLAZGO CRÍTICO — BUG DE LECTURA, YA CORREGIDO

read.delim(quote = "\"") truncó **2019_asamblea.tab** de 141.425 a 12.700 filas (-91%) sin ningún error ni warning — una comilla sin cerrar en un campo de texto rompe el parseo. Al cargar los 128 archivos completos aparecieron **4 casos más** del mismo bug (**2000_asamblea.tab**, **2000_concejo.tab**, **2019_concejo.tab**, **2023_concejo.tab**) — los 5 son asamblea/concejo, ninguno de cámara/senado/presidencia. El cargador ahora reintenta automáticamente con `quote = ""` y valida `nrow()` contra el conteo real de líneas antes de aceptar cualquier carga.

7.898

filas en 2.852 grupos de duplicados exactos, población completa — 60% concentrados en senado

71.460

filas con nombre de partido puramente numérico ("20180057"), no corrupto — confirmado: todas en 2018_senado.tab, ninguna en otro archivo

17–29%

de filas son voto-a-lista, no candidatura individual — varía por cargo (1,1% presidencia a 28,8% cámara), no un número único

IV. Trayectorias políticas

Identidad de persona **resuelta** (Cap. VI) sobre los 9 cargos — no solo cámara/senado/presidencia. Primera vez que se puede medir escalamiento local→nacional.

101.209

personas ganaron al menos una elección — 50,9% siguieron compitiendo después

2.822

personas con trayectoria local→nacional (concejo/alcaldía → cámara/senado/presidencia) — no medible antes de

20.140

candidatos con 3+ candidaturas distintas y cero victorias, 9 cargos


125.150

aristas en el grafo de trayectorias completo, listo para Gephi

Ejemplo real de escalamiento local→nacional encontrado en los datos: Juan José Acuña Colpas — alcaldía (1997) → concejo (2000) → alcaldía (2003) → senado (2022) → gobernación (2023). Este tipo de trayectoria era estructuralmente invisible antes de cargar asamblea, concejo, gobernación y alcaldía (Cap. II) y de resolver identidad de persona (Cap. VI) — con solo cámara/senado/presidencia y nombre crudo sin resolver, esta carrera se habría visto como 2 personas sin relación aparente.

Siete trayectorias nacionales, 1958–2022

Tres congresistas de trayectoria larga y tres presidentes/candidatos reconocibles, sobre el mismo eje de tiempo — recorte ilustrativo a cámara/senado/presidencia; el ejemplo de escalamiento local→nacional de arriba (Acuña Colpas) muestra el tipo de trayectoria que ahora es visible con los 9 cargos, aún no graficada aquí.



Antes de la reforma de 2003, cámara y senado se elegían mayormente por lista cerrada — el voto era al partido, no a la persona. Los tres congresistas de la fila superior aparecen reelegidos 9–10 veces con `votos_total = 0` en cada elección: no es un hueco de datos, es el diseño electoral de la época. Cualquier análisis de "cuántos votos sacó" tiene que filtrar por lista abierta (post-2003) o por presidencia, donde el voto siempre fue personal.

Candidatos seriales sin ganar nunca (extracto, 9 cargos)

20.140 personas con 3 o más candidaturas distintas y cero victorias — 44x más que con solo 3 cargos, porque las corporaciones locales concentran la mayoría de candidaturas perennes del país. Los 8 casos reales con más intentos (se excluyen "SDC"/"FUP"/"Socialdemócrata...", acrónimos de agrupaciones que el filtro de categorías-bolsa no distingue de personas, ver Cap. VI):

PERSONA (IDENTIDAD RESUELTA)	CANDIDATURAS	PRIMER AÑO	ÚLTIMO AÑO
Ospina Murillo J.	12	1997	2023
Rincón Sosa Rodolfo	12	2002	2023
Ariño Fernández F.	11	1994	2018
Hoyos Meneses L.	11	1997	2023
Jaramillo Castrillón	11	1997	2023
Robledo Lagarejo	11	1994	2023
Rodríguez Humberto	11	1964	2011
Bedoya Montoya J.	10	2006	2023

V. Migración partidista

Las mismas 3.426 aristas de la red de trayectorias, agregadas por partido en vez de por persona: 195 partidos, 445 pares origen→destino, listos para Gephi. *(Calculado sobre cámara/senado/presidencia — pendiente recalcular sobre los 9 cargos del Cap. IV.)*

195

partidos con al menos un salto de entrada o salida registrado

445

pares distintos partido origen → partido destino


28

personas migraron del Partido Liberal al Partido de la U — el salto más frecuente del histórico

Salto más frecuentes entre partidos, 1958–2022

Número de personas que compitieron bajo el partido de origen y, en su siguiente elección, bajo el de destino. Se excluyen del top los pares con una categoría-bolsa de un lado (ver Cap. III) — sí aparecen en el archivo completo para Gephi, marcados como tal.

Lib.→U		28
Lib.→C.Rad.		24
Cons.→ANAPO		16



Los saltos más frecuentes coinciden con episodios reconocibles de la historia política colombiana sin haberlos buscado a mano: la migración masiva de liberales hacia el Partido de la U y Cambio Radical en los 2000, conservadores hacia la ANAPO en los 70, y el regreso de excandidatos del Nuevo Liberalismo (la disidencia de Luis Carlos Galán) al Liberalismo tradicional. Esto es evidencia de que partido, aun derivado únicamente de texto crudo (Cap. I), captura señal política real.

El grafo completo — incluyendo migración partidista y trayectorias individuales — está en `poliTwin-colombia/output/gephi_*.csv`, listo para importar en Gephi (Archivo → Importar hoja de cálculo).

VI. Detección de outsiders

Un vector de 783.376 candidaturas × 21 variables, sin ninguna feature posterior al evento que predicen, sirve de base a tres métodos de anomalía — Isolation Forest, LOF y distancia de Mahalanobis — que coinciden en 557 casos.

783.376

candidaturas en el vector de features, 21 variables, sin fuga de información

231.912

candidaturas con al menos una elección previa — universo evaluado por los 3 métodos

557

candidaturas en el top 1% simultáneo de Isolation Forest y Mahalanobis

0,796

score máximo de aislamiento (Isolation Forest) — Gutiérrez Zuluaga F., alcaldía 2018, salto_nivel +3 desde la alcaldía

Top 8 por score de aislamiento (Isolation Forest)

Rango ~0–1, más alto = trayectoria más aislada del corpus histórico. Los ocho primeros del ranking completo son casos reconocibles de la política nacional — el método no usó nombres ni partido como variables, solo la forma de la carrera.

Petro '18 (1v)	0,796
Petro '22 (2v)	0,796
Petro '22 (1v)	0,793
Serpa Uribe	0,791
Petro '18 (2v)	0,791
Vargas Lleras	0,791
Vargas Lleras '10	0,788
García '18	0,787
Realpe	

DOS BUGS DE DATOS DEGENERADOS, ENCONTRADOS Y CORREGIDOS

Mahalanobis: la matriz de covarianza dentro de cada nivel de cargo era singular porque `nivel_anterior` es perfectamente colineal con `salto_nivel` una vez fijado el nivel — se excluyó del cálculo. **LOF:** miles de candidaturas de concejo comparten el mismo vector exacto (mismo cargo, mismo salto, cero elecciones previas), lo que producía distancias-cero y scores Inf. Un primer intento de romper los empates con ruido $sd=1e-6$ no alcanzó — los scores resultantes (~50.000) eran el mismo problema disfrazado; $sd=0.01$ sí produjo scores interpretables (11–46).

No toda anomalía estadística es un outsider político. Isolation Forest y Mahalanobis no distinguen una trayectoria insurgente de un error de captura o un caso administrativo raro. `salto_nivel` — cuántos niveles de cargo saltó una persona respecto a su elección anterior — es la señal más interpretable dentro del vector: un salto grande combinado con votación alta y pocas elecciones previas es la firma más cercana al sentido coloquial de "outsider" (Rodolfo Hernández 2022, salto de +3 desde la alcaldía de Bucaramanga a primera vuelta presidencial, aparece en el top 20 del ranking completo).

VII. ADN político — familias sin etiquetas externas

132.971 personas con dos o más candidaturas, resumidas en 9 dimensiones de carrera (experiencia, ambición, territorialidad, lealtad partidista, movilidad, resiliencia, velocidad, capacidad electoral, victorias). KMeans ($k=6$) separa una élite nacional de 3.472 personas sin que el modelo haya visto nunca un nombre.

Seis familias políticas (KMeans, $k=6$)

Ordenadas por capacidad electoral promedio. El cluster 1 concentra a Uribe, Petro, Duque, Santos, Pastrana y Hernández Suárez — la "élite nacional" emerge de los datos, no se definió a mano.


FAMILIA (EJEMPLO RECONOCIBLE)	PERSONAS	EXPERIENCIA (AÑOS)	TERRITORIALIDAD	CAPACIDAD ELECTORAL
Élite nacional — Uribe, Petro, Duque, Santos, Hernández	3.472	12,2	31,6	20.932
Ascendentes regionales — Gaviria Correa, Char Chaljub	9.577	12,0	1,3	2.834
Maquinarias regionales consolidadas	12.605	15,3	1,0	1.184
Persistentes de larga data	20.324	18,8	1,0	384
Debutantes leales	29.618	5,4	1,0	433
Política local de base	57.375	6,2	1,0	348

"¿Quién se parece a...?" — distancia euclidiana en el espacio ADN estandarizado. El vecino más cercano a Álvaro Uribe Vélez no es un aliado de su propio gobierno, sino Antanas Mockus (distancia 7,11) — ambos con trayectoria de outsider-a-poder-ejecutivo desde una sola plataforma regional. Y el hallazgo más nítido: **Gustavo Petro y Rodolfo Hernández son mutuamente su vecino más cercano** (distancia 7,79 en ambas direcciones) — dos trayectorias que la cobertura política de 2022 trató como opuestos ideológicos resultan, en la forma pura de la carrera (años de experiencia, saltos de nivel, velocidad de ascenso), el par más parecido de todo el corpus.

VIII. Red de poder

La migración partidista del Cap. V, ahora como grafo completo con PageRank, centralidad e intermediación: 4.401 partidos, 10.419 pares origen→destino. Las comunidades de Louvain reconstruyen los bloques políticos reales sin usar ninguna etiqueta ideológica externa.





2.003

partidos en la comunidad más grande (Louvain) — encabezada por La U, Cambio Radical y Alianza Verde

865

partidos en la comunidad del Liberalismo — encabezada por el Partido Liberal y el Nuevo Liberalismo

750

partidos en la comunidad del Conservatismo — encabezada por el Partido Conservador

243

partidos en la comunidad de izquierda — Polo Democrático y Pacto Histórico

El Partido Liberal Colombiano lidera en las tres métricas de centralidad a la vez (PageRank 0,0565, mayor grado de salida —12.861— e intermediación —3,87M—): es a la vez el mayor "puente" entre bloques que de otro modo no se conectarían y la mayor "cantera" de la que salen políticos hacia otros partidos. Las comunidades detectadas automáticamente por Louvain, sin ninguna etiqueta ideológica de entrada, agrupan a los partidos históricamente reconocidos como afines (liberalismo en un bloque, conservatismo en otro, izquierda en un tercero) — la migración partidista por sí sola contiene señal ideológica suficiente para reconstruirlos.

IX. Forecasting

Dos modelos randomForest, separación temporal entrenamiento/evaluación (no aleatoria, evita fuga de época) y solo variables conocidas antes del evento que predicen — verificado variable por variable, no por convención de nombre.

0,704

AUC — modelo A: ¿gana la elección actual? Entrena <2018, evalúa 2018+

80,9%

exactitud modelo A — 231.912 candidaturas, tasa base de "gana" 19,8%

0,779


AUC — modelo B: ¿llega a nivel nacional, predicho desde el debut?

8,39%

tasa base de "llega a nacional" — 132.971 personas con debut identificado

Modelo A — importancia de variables (Mean Decrease Accuracy)

La mejor señal de si alguien va a ganar es si ya ha ganado antes — no su partido, ni su crecimiento de votación, ni su expansión territorial.



HONESTIDAD SOBRE EL MODELO B

Con una sola variable disponible (nivel de la primera candidatura), el modelo B es **casi una regla de tres, no una predicción sofisticada** — se deja así a propósito, para no fingir señal donde el vector de outsider (Cap. VI) no la tiene todavía. El debut no incluye edad, formación, redes ni financiación: ninguna de esas variables existe en la fuente CEDE.

X. Simulador contrafactual

Un contrafactual concreto, no un motor genérico: ¿qué pasa con la red de poder (Cap. VIII) si Cambio Radical —el partido #4 por PageRank— se remueve del grafo de migración?

8.080

personas afectadas directamente — 13,9% de las 57.922 carreras del motor de trayectorias

460

de esas personas llegaron a nivel nacional — 277 específicamente en una candidatura de Cambio Radical

727

de 10.424 aristas del grafo de migración desaparecen al remover el partido

133 → 216

comunidades de Louvain sin el partido — la red se fragmenta más, no menos

El capital político no se redistribuye proporcionalmente: los tres mayores beneficiarios relativos en PageRank son los partidos ya dominantes de la misma comunidad de

migración —Conservador (+8,9%), Liberal (+7,0%), Alianza Verde (+5,7%)— mientras que partidos pequeños de la misma comunidad ganan más en términos porcentuales (Movimiento Alas Equipo Colombia, +18,6%) pero desde una base mucho menor. El capital heredado por la desaparición de un partido tiende a concentrarse en los partidos de maquinaria ya consolidados de su propio bloque, no a dispersarse hacia partidos emergentes.

Límite explícito del método: no modela a qué otro partido habrían migrado esas 8.080 personas si Cambio Radical nunca hubiera existido — eso requeriría un modelo causal de elección de partido que los datos de resultados electorales no sostienen por sí solos. Es un ejercicio de sensibilidad de red (¿qué tan central es este nodo?), no una simulación causal de la historia real.

XI. Dashboard — explorador interactivo

Los capítulos VI–VIII expuestos como herramienta de consulta, no solo como tablas estáticas: buscar cualquier político notable y ver su perfil ADN, su score de outlier y su carrera completa año a año.

11.625 personas "notables": llegaron a nivel nacional con carrera ≥2 elecciones, tienen ≥8 elecciones, o son outsider top 1%	6,14MB tamaño del JSON servido — recortado desde las 132.971 personas del ADN político completo (Cap. VII) para caber en un artifact autocontenido
--	--

Cada ficha combina el perfil de 9 dimensiones del ADN político (Cap. VII) contra el promedio de su familia, su score de anomalía si aplica (Cap. VI), y su trayectoria año a año reconstruida del motor de trayectorias (Cap. IV) — con nivel de cargo codificado por color (local, regional, nacional legislativo, nacional ejecutivo) y resultado (elegido / no elegido) por relleno del punto.

XII. Resolución de entidades — implementada

Lo que en la primera revisión era diseño (docs/RESOLUCION_ENTIDADES.md) ya se ejecutó sobre partido y persona, incluyendo el escalamiento de partido a los 9

cargos completos. El caso Robledo, citado como el límite abierto del informe anterior, ya está resuelto.

Persona: el caso Robledo se resuelve — y aparece un bug nuevo

"Robledo Castillo Jorge" (2006) y "Robledo Castillo Jorge Enrique" (2010–2018) ahora se fusionan en la misma identidad — bloqueo por apellidos + primer nombre, coincidencia por subconjunto de tokens del resto. El control negativo también funciona: "Robledo Castillo Carlos Alberto", una persona real distinta con el mismo apellido, queda correctamente separado.

BUG ENCONTRADO DURANTE LA IMPLEMENTACIÓN, NO ANTICIPADO EN EL DISEÑO

El subconjunto de tokens no es transitivo. "LUIS" es subconjunto de "LUIS ALFONSO", "LUIS CARLOS" y "LUIS MARIA" a la vez — fusionar las tres transitivamente vía ese "puente" corto las mezcla aunque sean personas distintas. Se corrigió con una validación de compatibilidad de grupo: rechazar cualquier cluster donde no *todos* los pares internos sean directamente compatibles, no solo unidos vía un tercero. **513 de 4.236 grupos candidatos (12%) cayeron en esta categoría** y quedaron sin fusionar — conservador a propósito.

555.480

personas distintas (nombre normalizado) en el corpus de 9 cargos

3.748

pares fusionados en 3.723 clusters, tras rechazar los ambiguos

0,69%

tasa de reducción — baja en términos absolutos, pero es la cifra correcta después del fix, no antes

Partido: 50% de falsos positivos incluso después del bloqueo

Bloqueo por década + exclusión geográfica y temporal explícita sobre 769 candidatos (de 834, tras remover 65 categorías-bolsa) produjo 6 clusters — revisados a mano: **2 fusiones correctas** (ej. "Consejo Comunitario Río Curbarado/Curvarado", variante de tipeo de un lugar real), **3 falsos positivos** ("Movimiento Nueva Colombia" vs "Fuerza Colombia" — palabras con significado propio, no una variante tipográfica) y 1 caso parcial. El bloqueo elimina los falsos positivos *estructurales* (Cap. III), pero no distingue una palabra distinta de un error de tipeo cuando ambas tienen longitud similar.

Escalado a los 9 cargos completos (`scripts/14_resolver_partido_completo.R`): 7.168 partido distintos, 8,6× más que los 834 de cámara/senado/presidencia. El bloqueo solo por década no alcanzó a esta escala — el bloque de la década 2010 (6.770 candidatos) no terminó en 10 minutos con `adist()` vectorizado; se agregó sub-bloqueo por primera palabra significativa del nombre, bajando el tiempo a menos de un minuto. Resultado: 209

categorías-bolsa removidas, **47 clusters, 56 pares fusionados** (6.959 → 6.909 identidades, 0,72% de reducción — el mismo orden de magnitud que persona a escala completa, Cap. XII abajo).

HALLAZGO NUEVO A ESTA ESCALA — EL FALSO POSITIVO DOMINANTE CAMBIA

A 834 partidos, los falsos positivos eran principalmente palabras con significado propio ("nueva" vs "fuerza"). A 7.168, **al menos 13 de 25 clusters de la muestra (52%) son coaliciones municipales con el mismo patrón de nombre y el mismo departamento, pero municipio distinto** — ej. "COALICION ALCALDIA DE FOSCA-CUND..." vs "...DE COTA-CUND..." (Fosca y Cota son municipios distintos de Cundinamarca). La exclusión geográfica de §3.3 solo compara departamento, no municipio — a escala nacional casi no importaba, pero al incluir concejo/alcaldía (miles de coaliciones con la misma estructura de nombre repetida por municipio) se vuelve el modo de falla dominante. **Refinamiento necesario antes de producción:** extender la exclusión para comparar también nombre de municipio — el MDM ya tiene esa columna disponible, no requiere una fuente nueva.

XIII. Estrategia — síntesis, no motor genérico

Un motor de recomendación genérico ("a qué partido afiliarse", "qué territorio priorizar") necesitaría encuestas, financiación y coyuntura que este proyecto nunca tuvo. Lo que sí sostienen los capítulos VI–XI son tres productos de consulta concretos.

Radar de candidaturas 2022–2023 con perfil atípico (Cap. VI)				
Top 8 por score de aislamiento entre candidaturas de los dos años más recientes de la base — una lista de personas a observar, no un veredicto: los datos más recientes no tienen aún trayectoria futura que confirme o descarte el patrón.				
PERSONA	AÑO	CARGO	SALTO DE NIVEL	SCORE
Petro Urrego Gustavo F.	2022	Presidencia (2ª vuelta)	0	0,796
Villalba Mosquera Rodrigo	2023	Gobernación	−1	0,786
Robledo Castillo Jorge E.	2023	Alcaldía	−2	0,784
Gutiérrez Zuluaga Federico A.	2023	Alcaldía	−3	0,782
Durán Barrera Jaime E.	2022	Senado	0	0,782
Toro Torres Dilian F.	2023	Gobernación	0	0,781
Hernández Suárez Rodolfo	2022	Presidencia (1ª vuelta)	+3	0,778

PERSONA	AÑO	CARGO	SALTO DE NIVEL	SCORE
Amin Escaf Miguel	2022	Senado	0	0,775

Mapa de riesgo de coalición (Cap. VIII, X)

El contrafactual de Cambio Radical (Cap. X) generaliza: el capital político migrado por la desaparición de un partido se concentra en los partidos ya dominantes de su propia comunidad de migración, no se dispersa hacia partidos emergentes — un patrón consistente con la literatura sobre partidos de maquinaria en sistemas fragmentados como el colombiano.

Comparación de perfil contra la familia política (Cap. VII, XI)

Ya implementado como funcionalidad del dashboard (Cap. XI): cada ficha compara al candidato contra el promedio de su cluster y contra perfiles de referencia reconocibles — el ADN político (Cap. VII) expuesto como herramienta de consulta en vez de tabla estática.

Qué requeriría un motor real, no construido aquí: una función objetivo explícita (depende de juicio político, no de datos), variables de contexto actuales (encuestas, financiación, coyuntura — ausentes en CEDE) y validación fuera de muestra sobre al menos un ciclo electoral no visto durante el diseño. Documentar esto en vez de aparentar más certeza de la que los datos sostienen es la misma disciplina aplicada desde el Cap. I.

XIV. Límites y siguiente paso

Sin cédula o ID de Registraduría, la identidad de persona seguirá siendo probabilística, no determinística — el techo de este método es mejor que el nombre crudo, no perfecto. Homónimos verdaderos sin contexto discriminante (misma persona, mismo departamento, cargos similares en años cercanos) quedan ambiguos por diseño, no por error.

Ningún modelo analítico (Cap. VI–X) usa encuestas, cobertura mediática, financiación de campaña ni coyuntura — todos predicen sobre la *forma* de la carrera política, no sobre eventos exógenos. Esto es una limitación estructural de la fuente (CEDE, resultados electorales), no del método.

Refinamiento identificado para la siguiente iteración (aplica a partido y persona por igual): cuando dos nombres difieren en exactamente un token, tratar la fusión como

candidata solo si ese token es una palabra-función ("de", "la") o si el par de tokens tiene distancia de edición ≤ 2 *sobre ese token únicamente* — no sobre el string completo, que es lo que hoy fusiona "renovación" con "revolución" cuando no debería, y no fusiona "Curbarado" con "Curvarado" a menos que el resto del nombre sea idéntico.

Línea de investigación pendiente: territorios adelantados — municipios que cambian antes que la tendencia nacional (lead-lag correlation, dynamic time warping, Granger) — es la única de las 8 líneas de investigación del roadmap (docs/ROADMAP.md) sin construir todavía.

Siguiente paso concreto: extender la exclusión geográfica de resolución de partido a nivel de municipio (Cap. XII); recalcular la red de migración partidista (Cap. V, VIII) sobre los 9 cargos completos, no solo cámara/senado/presidencia; y construir territorios adelantados como la línea de investigación restante.